Identificación asistida de plantas de interés forrajero del Cibao

Prototipo educativo de clasificación de imágenes para las clases de Pastos y Forrajes
Documento técnico de avance | 9 de noviembre de 2026

1. Problema y justificación

La inquietud del proyecto surge de la necesidad expresada por el docente de identificar plantas durante el desarrollo de las clases del politécnico. Los nombres comunes y las diferencias de aspecto entre fotografías pueden dificultar la comparación de ejemplares. Se propone una herramienta que sugiera una identidad entre cuatro especies seleccionadas y permita discutir esa propuesta mediante observación y revisión docente.

El ámbito educativo previsto es el Cibao dominicano. Las imágenes disponibles proceden principalmente de observaciones internacionales; por ello, el ámbito de uso previsto no equivale a una validación regional del modelo. Este trabajo desarrolla un prototipo técnico y no demuestra una mejora del aprendizaje.

2. Pregunta de investigación, variables e impacto

Pregunta orientada a Machine Learning. ¿Qué desempeño preliminar obtiene el clasificador de las cuatro especies al evaluar fotografías separadas por firma de autor en esta muestra de conveniencia?

Elemento	Definición en el proyecto
Variable objetivo (target)	Etiqueta de clase correspondiente a una de las cuatro especies seleccionadas.
Variables de entrada del modelo	Representaciones numéricas calculadas a partir de los píxeles: histogramas de color y orientación de bordes por zonas; o características visuales extraídas por MobileNetV3 Small.
Metadatos de trazabilidad	Identificador y enlace de observación, licencia, atribución, autor y localidad reportada. Se emplean para documentar y definir particiones; no son predictores de especie.
Población impactada	Docente y estudiantes de agropecuaria que realizan identificación guiada de plantas en las clases de Pastos y Forrajes. No se midió impacto en estudiantes.

3. Objetivos

General. Desarrollar y evaluar preliminarmente un prototipo de clasificación de imágenes de cuatro plantas de interés forrajero, como apoyo a la identificación guiada en clases agropecuarias.

Específicos. Organizar imágenes con trazabilidad y licencias; comparar clasificadores mediante particiones agrupadas; integrar un modelo en una aplicación que reciba fotografías; y documentar resultados, limitaciones y condiciones de uso educativo.

4. Delimitación del proyecto

Nombre empleado	Clase científica
Piñón cubano	Gliricidia sepium
Hierba de Guinea	Megathyrsus maximus
Grama de Bermuda	Cynodon dactylon
Pasto bahía	Paspalum notatum

La yerbita de leche queda excluida por decisión del autor. La predicción visual no determina valor nutritivo, inocuidad, dosis ni aptitud de un ejemplar para alimentación animal.

5. Datos y trazabilidad

Se incorporaron 77 fotografías reducidas de observaciones de iNaturalist. El cuaderno conserva por registro la especie, observación, enlace, licencia, atribución, localidad reportada y representación de la imagen. Las consultas seleccionaron observaciones con grado de investigación y licencias CC BY, CC BY-SA o CC0. Esta clasificación comunitaria no sustituye una revisión botánica independiente (iNaturalist, s. f.).

Clase	Fotografías
Gliricidia sepium	27
Megathyrsus maximus	19
Cynodon dactylon	15
Paspalum notatum	16
Total	**77**

Se eliminaron duplicados exactos y se conservó una fotografía por observación. La selección es de conveniencia, pequeña y desigual. Las diferencias de órganos visibles, fondo, encuadre y autor pueden afectar el aprendizaje del clasificador. El cuaderno incluye una revisión visual preliminar que requiere corroboración especializada.

6. Preparación, particiones y metodología

La identificación geográfica se basó en el texto de localidad reportado; debe verificarse posteriormente con coordenadas y límites administrativos. Se reservaron 14 observaciones consideradas dominicanas: 11 de Gliricidia sepium y 3 de Megathyrsus maximus. Esta reserva carece de las otras dos clases y no se utilizó para calcular exactitud local.

Las 63 imágenes restantes se dividieron por firma de autor en 47 de desarrollo y 16 de prueba exploratoria. Se eligió, con semilla 42, una partición que representara las cuatro clases en ambos conjuntos. Las 16 imágenes fueron inspeccionadas durante la exploración y no deben presentarse como una prueba final intacta.

Sobre las 47 imágenes de desarrollo se aplicaron tres particiones con StratifiedGroupKFold, agrupando por firma de autor y utilizando las mismas divisiones para los modelos comparados. Esta estrategia busca separar autores entre ajuste y validación (scikit-learn developers, s. f.). No garantiza separar ejemplares si distintas personas fotografiaron la misma planta.

7. Enfoque de Machine Learning y modelos

Se trata de clasificación supervisada multiclase: las fotografías tienen una etiqueta de especie conocida y el sistema asigna una de las cuatro clases. Se eligieron modelos acotados que permiten contrastar una referencia simple, características visuales calculadas y transferencia de características con un modelo preentrenado.

Como referencia se utilizó la clase más frecuente. La regresión logística y el bosque aleatorio emplearon 128 características manuales de color y orientación de bordes calculadas en cuatro zonas de cada imagen. El escalado de la regresión se ajustó dentro de cada partición.

El tercer enfoque empleó MobileNetV3 Small con pesos IMAGENET1K_V1, congelado y sin su clasificador original. Se extrajeron 576 características por imagen y se ajustó una regresión logística con estandarización y balance de clases. Se utilizaron las transformaciones correspondientes a los pesos oficiales (PyTorch Contributors, s. f.). No se entrenó una red neuronal desde cero.

8. Evaluación y resultados ejecutados

Los resultados corresponden a medias de tres particiones internas. No representan exactitud en el Cibao ni desempeño demostrado con estudiantes.

Método	Exactitud media	F1 macro medio
Clase más frecuente	32,1 %	0,121
Regresión logística	30,1 %	0,304
Bosque aleatorio	31,8 %	0,313
MobileNetV3 + regresión logística	46,9 %	0,478

MobileNetV3 alcanzó 18,8 %, 53,3 % y 68,8 % de exactitud en las tres particiones, respectivamente. La desviación estándar entre particiones fue aproximadamente 25,6 puntos porcentuales. La variación indica una estimación inestable por el tamaño y composición de la muestra. La ventaja observada frente a las alternativas no demuestra superioridad generalizable.

En la prueba exploratoria de 16 imágenes, la regresión logística de características manuales acertó 1 imagen: 6,25 % de exactitud y F1 macro de 0,056. Corresponde a un modelo y evaluación distintos de la validación interna de MobileNetV3; se informa para evitar una presentación selectiva de resultados.

9. Prototipo, interpretación y riesgos

El clasificador local MobileNetV3 + regresión logística compara la fotografía con las cuatro clases y solo puede proponer una de ellas; por sí mismo no confirma que una planta pertenezca al catálogo.

Al solicitar el análisis, la aplicación envía a Pl@ntNet una copia JPEG sin metadatos EXIF para obtener una candidata taxonómica externa. La compara con las cuatro clases y señala cuando la candidata queda fuera del catálogo. Cuando está disponible, muestra una referencia taxonómica de GBIF. La consulta requiere una clave API privada configurada en Streamlit Secrets.

Pl@ntNet y el clasificador local producen propuestas automáticas, no confirmaciones botánicas. Si la consulta externa falla o no devuelve candidata, no se presenta una identificación local forzada. La revisión docente sigue siendo necesaria; la consulta externa no valida la presencia local en campo ni el efecto educativo, y la predicción no debe utilizarse para decidir la alimentación del ganado.

10. Conclusiones y estado

Se construyó una cadena reproducible desde imágenes documentadas hasta un clasificador exportable. La transferencia de características obtuvo el mejor promedio interno de los métodos ensayados, pero la variabilidad y el tamaño de la muestra exigen mantener el carácter experimental. La muestra local incompleta impide concluir que el sistema identifica confiablemente las cuatro especies en el contexto previsto.

El prototipo puede servir para contrastar una propuesta automática con la observación de la planta y discutir errores de clasificación. No se realizaron intervenciones con estudiantes ni mediciones del aprendizaje; por tanto, no se atribuyen efectos pedagógicos comprobados.

El video explicativo forma parte de los entregables. La aplicación está operativa; su URL funcional debe quedar registrada en el README. No se realizaron validación botánica de campo ni mediciones de aprendizaje.

Referencias

iNaturalist. (s. f.). API reference. https://www.inaturalist.org/pages/api+reference

PyTorch Contributors. (s. f.). mobilenet_v3_small. Torchvision documentation. https://docs.pytorch.org/vision/main/models/generated/torchvision.models.mobilenet_v3_small.html

scikit-learn developers. (s. f.). StratifiedGroupKFold. Scikit-learn documentation. https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedGroupKFold.html

Cook, B. G., Pengelly, B. C., Schultze-Kraft, R., Taylor, M., Burkart, S., Cardoso Arango, J. A., González Guzmán, J. J., Cox, K., Jones, C., & Peters, M. (2020). Tropical Forages: An interactive selection tool (2nd rev. ed.). CIAT & ILRI. https://www.tropicalforages.info/

Chintala, R., Haller, S., & Holleman, B. (2023). Plant guide for bahiagrass (Paspalum notatum). USDA Natural Resources Conservation Service, Booneville Plant Materials Center. https://www.nrcs.usda.gov/plantmaterials/arpmcpg14045.pdf

Respaldo técnico para las clases del proyecto

Nombre usado en el proyecto	Nombre científico	Fuente
Piñón cubano	Gliricidia sepium	Cook et al. (2020)
Hierba de Guinea	Megathyrsus maximus	Cook et al. (2020)
Grama de Bermuda	Cynodon dactylon	Cook et al. (2020)
Pasto bahía	Paspalum notatum	Cook et al. (2020); Chintala et al. (2023)

Los perfiles respaldan la nomenclatura y describen rasgos y usos generales; no confirman la etiqueta de cada fotografía ni la presencia de estas especies en el Cibao. La distribución local requiere verificación de campo.